

北京航空航天大学

2024-2025 学年 第二学期期末

基于大模型的英文论文写作辅助工具
设计与开发实验报告

课 程 数据挖掘

小 组 G233

姓 名 关凯文

杨 绎

陈昊昉

黄逸菲

李思睿

导 师 季书帆


2025 年 6 月 26 日

目录

1 大模型调研与部署	3
1.1 大模型写作评测	3
1.2 大模型部署与调用实验	4
1.3 api 调用	8
2 基于 Agent 的 RAG 框架设计	9
2.1 RAG 框架	10
2.2 RAG 预期解决的问题	11
3 提示词工程设计与实验	13
3.1 高水平论文撰写工具与提示词参考	13
3.2 提示词实验	13
4 前端与运行结果	16
4.1 相关参考工作流实验	16
4.2 Pipeline 规划	17
4.3 实验结果	18
Reference	23
附件 实验详细记录	24
3 虚拟数据构造与基于结果的论文实验	24

图：benchmark 评估话题

使用单一标准评估无法适应不同写作意图的需求，就像“悬疑小说”和“儿童启蒙故事”显然有着不同的价值导向。因此，WritingBench 设计了一种基于写作意图自动生成评测指标的方法，模型可以针对每个写作输入自动生成五个评测指标的名称、描述和评测细则，以更好地结合素材和用户实际需求（如仿照上传素材的风格、格式或结合提供的事例进行材料撰写）。此动态评估策略实现了 87% 的人类一致性得分，团队还配套训练了一个评分模型，能够根据不同指标自适应地给出 1-10 分的评分及具体理由。



图：评估细则

Models	Avg	Languages			Domains					Requirements					
		ZH	EN	D1	D2	D3	D4	D5	D6	R1	C	R2	C	R3	C
Proprietary LLMs															
ChatGPT-4o-latest	8.16	8.3	8.1	8.1	8.1	8.2	8.1	8.4	8.1	8.3	8.7	8.2	8.9	8.2	8.3
o1-Preview	8.15	8.1	8.2	8.0	8.1	8.2	8.2	8.4	8.1	8.2	8.6	8.2	8.8	8.2	8.2
Claude-3.5-Sonnet	7.71	7.7	7.7	7.6	7.5	7.6	7.7	7.9	8.0	7.9	8.5	7.7	8.5	7.9	8.0
Gemini-1.5-Pro	7.78	7.8	7.7	7.7	7.5	7.8	7.9	8.0	7.9	7.9	8.6	7.9	8.8	7.9	8.0
Qwen-Max	8.37	8.4	8.3	8.3	8.3	8.4	8.4	8.5	8.4	8.5	8.7	8.4	9.0	8.4	8.5
Open-source LLMs															
Deepseek-R1	8.55	8.7	8.5	8.5	8.5	8.6	8.6	8.7	8.6	8.7	8.9	8.6	9.0	8.6	8.7
Deepseek-V3	7.95	8.0	7.9	7.9	7.8	8.0	7.8	8.2	8.0	8.1	8.6	8.0	8.9	8.0	8.2
Mistral-Large-Instruct	7.64	7.6	7.7	7.7	7.6	7.8	7.3	7.9	7.6	7.7	8.2	7.7	8.7	7.7	7.9
Qwen-2.5-72B-Instruct	7.90	8.0	7.9	8.0	7.8	8.1	7.7	8.2	7.8	8.0	8.3	8.0	8.8	7.9	8.0
Qwen-2.5-7B-Instruct	7.43	7.3	7.5	7.7	7.4	7.6	6.9	7.8	7.3	7.5	7.9	7.6	8.6	7.4	7.5
Llama-3.3-70B-Instruct	7.01	6.7	7.3	7.0	6.9	7.0	6.8	7.3	7.3	7.1	7.8	7.1	8.2	7.0	7.2
Llama-3.1-8B-Instruct	6.35	5.7	6.9	6.6	6.4	6.1	6.0	6.7	6.6	6.4	7.0	6.4	7.6	6.3	6.4
Capability-enhanced LLMs															
Suri	4.97	4.4	5.5	5.6	5.3	5.0	4.1	5.0	5.1	4.8	5.2	5.0	5.4	4.5	4.0
LongWriter	7.91	7.9	7.9	8.0	8.1	8.1	7.7	8.1	7.6	7.9	8.2	8.1	8.8	7.7	7.7
Qwen-2.5-7B-filtered	8.49	8.6	8.4	8.4	8.4	8.6	8.4	8.6	8.5	8.6	8.8	8.5	9.0	8.5	8.6
Llama-3.1-8B-filtered	8.49	8.6	8.4	8.5	8.4	8.6	8.4	8.6	8.5	8.6	8.8	8.5	8.9	8.5	8.5

Table 3: WritingBench performance of different LLMs across 6 domains and 3 writing requirements evaluated with our critic model (scale: 1-10). The six domains include: (D1) Academic & Engineering, (D2) Finance & Business, (D3) Politics & Law, (D4) Literature & Art, (D5) Education, and (D6) Advertising & Marketing. The three writing requirements assessed are: (R1) Style, (R2) Format, and (R3) Length. Here, "C" indicates category-specific scores.

图：不同模型的表现

使用单一标准评估无法适应不同写作意图的需求，就像“悬疑小说”和“儿童启蒙故事”显然有着不同的价值导向。因此，WritingBench 设计了一种基于写作意图自动生成评测指标的方法，模型可以针对每个写作输入自动生成五个评测指标的名称、描述和评测细则，以更好地结合素材和用户实际需求（如仿照上传素材的风格、格式或结合提供的事例进行材料撰写）。此动态评估策略实现了 87% 的人类一致性得分，团队还配套训练了一个评分模型，能够根据不同指标自适应地给出 1-10 分的评分及具体理由。


[illegible]

1.2 大模型部署与调用实验

在线部署方法：

1. 阿里云百炼 api 平台

<https://bailian.console.aliyun.com/?tab=home#/home>



图：阿里云百炼界面

本地部署方法：

1. Ollama，快速原型验证与研究实验

功能：支持 GGUF、Safetensors; Modelfile 自定义

硬件：CPU, GPU

API 接入：CLI, Python/JS SDK, REST API

扩展：Community UI

```

26 curl -fsSL https://ollama.com/install.sh | sh
27 ollama list
28 ollama run llama3.2
29
30 netstat -tuln | grep 11434
31 tcp      0      0 0.0.0.0:11434 0.0.0.0:*  LISTEN
32
33 nginx setting:
34 server {
35     listen 20810;
36     server_name **;
37
38     location /api/ {
39         proxy_pass http://localhost:11434/api/;
40         proxy_set_header Host $host;
41         proxy_set_header X-Real-IP $remote_addr;
42         proxy_set_header X-Forwarded-For $proxy_add_x_forwarded_for;
43         proxy_set_header X-Forwarded-Proto $scheme;
44     }
45 }
46
47 ln -s /etc/nginx/sites-available/ollama /etc/nginx/sites-enabled/
48 nginx -t
49 systemctl restart nginx

```

图：Ollama 部署

2. Vllm, 高吞吐、低延迟的生产级推理引擎

功能：支持 LoRA、前缀缓存

硬件：NVIDIA GPU, AMD GPU/CPU, TPU, Gaudi, Neuron

API 接入：OpenAI-Compatible Server, Python API

扩展：插件系统

```

28 conda create -n vllm python=3.10
29 conda activate vllm
30 pip install vllm==0.8.2
31
32 mkdir models
33
34 export HF_ENDPOINT=https://hf-mirror.com; \
35 huggingface-cli download --resume-download \
36 Qwen/Qwen2.5-72B-Instruct-1M \
37 local_dir models/Qwen2.5-72B
38
39 cd /home/user/
40 conda activate vllm
41
42 vllm serve models/Qwen2.5-72B \
43 --host 0.0.0.0 \
44 --port 8080 \
45 --tensor-parallel-size 4 \
46 --enforce-eager \
47 --gpu-memory-utilization 0.9

```

图：Vllm 部署

3. Xinference

硬件要求：实验配置了四张 A800 GPU 显卡 跑 QWEN3-72B-INT8

操作系统：支持 Linux 或 Windows 操作系统。

Docker：可安装并配置好 Docker 环境，以便利用 Docker 容器进行 Xinference 的部署和管理。

模型

qwen3 CHAT

参数

温度 ?

0

Top P ?

1

最大生成长度 ?

40960

存在惩罚 ?

0

频率惩罚 ?

0

停止序列 ?

输入序列并按 Tab 键

添加 Xorbits Inference

模型类型 *

LLM

Text Embedding

Rerank

Speech2text

TTS

模型名称 *

qwe3

如何部署 XInference

取消

保存

您的密码将使用 PKCS1_OAEP 技术进行加密和存储。

图：Xinference 设置部署

1.3 api 调用

在线 api 调用代码

```
def call_deepseek_model(prompt:list, model:str, temperature=0):
    """调用 Deepseek 模型"""

    client = openai.OpenAI(
        api_key=os.getenv("DASHSCOPE_API_KEY"),
        base_url="https://dashscope.aliyuncs.com/compatible-mode/v1"
    )

    response = client.chat.completions.create(
        model=model,
        messages=prompt,
        temperature=temperature,
        max_tokens=8192
    )

    return response.choices[0].message.content

def call_aliyun_model(prompt:list, model:str, temperature=0):
    """调用阿里云模型"""

    """参数:
    model: 阿里云模型名称 (以"aliyun/"开头)"""


    client = openai.OpenAI(
        api_key=os.getenv("ALIYUN_API_KEY"),
        base_url="https://dashscope.aliyuncs.com/compatible-mode/v1",
    )

    reasoning_content = ""
    answer_content = ""
```


2 基于 Agent 的 RAG 框架设计

RAG 预期解决如下问题：首先，特定领域下 LLM 的知识缺失，导致胡言乱语；LLM 只能接受训练前的知识，而无法接触到最新知识。第二，拥有联网搜索功能后，LLM 可以一定程度上解决幻觉问题，但是网络上可以搜索到的内容大多为博客、分享等，不具有权威性，质量参差不齐。第三，某些专业领域的相关知识可能无法在网络上直接搜索到，导致 LLM 无法回答。

RAG 通过将相关的专业内容构成知识库（文档、表格、PDF 等多种形式），利用外部知识库检索，增强 LLMs 生成内容的准确性。



图：RAG 运行逻辑示意图

RAG 在架构上通常由三部分组成^[1]：LLM - Tool - Orchestrater

其中，LLM 是大语言模型。根据应用场景，可选择大型思考模型（如 deepseekR1, O4-mini-high, Qwen max），微调模型，小型模型。根据使用场景选择合适的模型，以致进行微调，可以平衡开销成本、开发成本、使用效果。Tool 是框架工具，包括 Tool 工具和 Protocol 协议。框架工具的意义在于将 LLM 嵌入一个具有明确任务、明确输入输出的工作流中，增强 LLM 在特定任务中的信息检索、分析、执行能力。更重要的是，工作流可以确保输出符合某些限制、确保输出质量，这作为现实工具使用 and 商业化应用中特别重要。Orchestrater 是前端与呈现，又称 Interface。将具体的执行结果呈现给用户。该步主要涉及 UX，在现实商业场景中研究较多（例如 LLM 输出可理解分析）。整个架构的组成方法称为工作流 Workflow


框架包含以下数个部分：

- Workflow: 构建工作流的框架。可以简单的 python 脚本，也可以使用 Langchain 等标准框架
- Tools: 大模型可调用的其他工具，包括数据库、查询工具、执行工具，甚至是执行其他任务的大模型
- Protocols: 大模型与其他工具的通信协议，例如 Anthropic 的模型上下文协议 (MCP)，以及 Google 的智能体间协议 (A2A)
- Orchestrater: 将工作流和结果呈现给用户

2.1 Workflow

workflow 工具流构筑框架选择需要对具体任务进行方法进行设计

Workflow 框架用于减小开发负担，流程化项目开发，但不能替代开发者对项目流程的良好设计



图：智能体的架构

当前个人开发的主流 Workflow 工具：

- Python：对于明确定义、无需复杂工作链条的任务，可以直接使用 Python 实现。


优点：开发简单，直接，高度自定义，初期工作量小，适合良好设计的项目流程快速开发

缺点：硬编码，难以拓展

- Langchain：可拓展的 AI Agent 框架，使用最广泛

优点：完整的大模型运行框架，功能最强大，泛用性最大

缺点：需要一定时间学习框架使用、配置



图：LangChain 部署方法

部署例子：

步骤一：索引

加载：首先需要加载数据，可以使用 DocumentLoaders 库。

拆分：文本拆分器将大型文档拆分成更小的块。这对于索引数据和将数据传递给模型都很有必要，因为大块更难搜索，也不适合模型的有限上下文窗口。

信息存储：需要一个地方来存储和索引我们的拆分，以便以后可以搜索它们。通常使用 VectorStore 和 Embeddings 模型来完成。

步骤二：检索和生成

检索：给定用户输入，使用 Retriever 从存储中检索相关拆分。

生成：ChatModel/LLM 使用包含问题和检索到的数据的提示生成答案。

- Coze：字节跳动的 AI Agent 框架

优点：零代码，可视化编排工具，集成大量工作，适合快速搭建 POC 验证想法

缺点：功能受限，需要付费


2.2 Tool

Tool 工具包含了大模型所需的任何工具。总的来说，可以分为以下几类：

- 信息检索。包括数据库、互联网搜索工具、文件搜索等
- 任务执行。例如代码运行、外界工具使用、计算机操作与命令行运行
- 调用其他模型。例如使用较大的 Thinking LLM 作为 Planner，对某一模糊问题进行规划，然后将规划结果输出给小参数 LLM 具体进行执行，隔离 Context Window

以下利用一个简单的 RAG 例子介绍 Tool：

例子中主要使用的 Tools 包含向量数据库（包括 Faiss, Milvus 和 GaussDB 等）和检索工具



图：典型 RAG 框架中的 Tools

2.3 Protocols

LLM 理论上可以调用任何的程序，只要程序的输入和输出符合某种“规范”。目前有两种协议定义了这种规范：

- MCP

Anthropic 提出的开源协议，用于 Tools 和 LLM 间通过 JSON-RPC 交换上下文和工具调用信息。

优点：确定性执行与可追溯性、低令牌开销、成本可控

缺点：不涵盖 Agent 间直接通信，且各 agent 间需要专门配置协议格式和 MCP 服务器

- A2A

Google 提出的协议，以结构化对话为载体，支持智能体自发分工、委派子任务及运行时生成新 Agent，不同组织或框架下的 Agent 可通过统一的 A2A 协议发现彼此并协作。

优点：功能更强，无需预定义 API，较贴近人机交流习惯，易于原型快速迭代。

缺点：开销较大，可控性和回溯性不足

2.4 Orchestrater

- Gradio：用于快速创建和分享机器学习模型的交互式界面。通过简单的代码将模型、函数或数据处理流程转化为易于使用的 web 应用，适合演示、测试和部署机器学习模型，无需复杂的前端开发即可让用户通过浏览器与模型交互。

- RAGFlow：是一种融合了数据检索与生成式模型的新型系统架构，其核心思想在于将大规模检索系统与先进的生成式模型相结合，适合处理特别复杂的文档和非结构化数据

- Dify：提供了用户友好界面和一系列强大的工具，能够快速搭建生产级的 AI 应用，适合多模型协作和复杂业务流程的场景

Dify 安装例子：

Step 1: Dify 配置，即安装 Dify

https://link.zhihu.com/?target=https%3A//mp.weixin.qq.com/s%3F_biz%3DMzk00TY1MTM00A%3D%3D%26mid%3D2247484622%26idx%3D1%26sn%3D4c7fd913f9667804f52b3da63263fa2e%26scene%3D21%23wechat_redirect

Step 2: RagFlow 配置，安装 RAGFlow 并启动，浏览器打开 并 注册并登录在网页中新建知识库并上传数据集，解析成功获得知识库 id

Step 3: Dify 外挂 RAGFlow

配置外部知识库 API：将 RAGFlow 信息对应配置到 Dify 上

创建外部知识库：选择知识库 API--填入对应知识库 id--点击连接

Step 4: 实测表格、图片、公式，提问知识库中的信息，效果良好

3 提示词工程设计与实验

3.1 高水平论文撰写工具与提示词参考

具体提示词参考了 Openai 公开智能体中评分最高的 7 个学术写作工具。
参考提示词整理于开源仓库中

<https://github.com/passingby000/DataMiningG233/tree/main>

	智能体	使用量 (conversations)	评分(满分 5)
1	AI Paper Polisher Pro	25000+	4.4
2	Thesis Supervisor	10000+	4.4
3	Master Thesis Writer	25000+	4.1
4	Academic Thesis/Dissertation Generator	1000+	4.4
5	Doctoral Writing Assistant	1000+	4.6
6	Research R&D Academic Paper Writer Scholar Report	50000+	4.3
7	Research: Academic, Paper, Scholar, Report	4200+	4.2

3.2 提示词实验

1 实验设计与目标

通过系统化提示词工程实验,验证不同提示策略对学术写作任务的质量影响,覆盖论文全模块(标题/摘要/引言/方法/结果/结论)。实验采用控制变量法:

①基础提示词 : 预设学术专家身份指令

"Act as an experienced academic writing expert specializing in [field]..."

②增强提示词 : 基础提示+结构化内容约束

3. 对比组 : 无角色设定的通用指令

2 实验结果

①标题生成

增强提示: Generate a title for my paper on [topic]. The title should be no more than 15 words, use precise academic terms to summarize the research content, and be engaging enough to reflect the core findings and attract academic interest.

提示策略	生成示例 (ICL 领域)	评分
------	---------------	----

提示策略	生成示例（ICL 领域）	评分
基础提示	"Advances in Unsupervised In-Context Learning"	3.2
增强提示	"Unsupervised ICL: Bridging Computational Intractability to Real-World Applications"	4.8
通用指令	"A New Method for Learning Without Labels"	2.5

②摘要生成

增强提示: Generate a title for my paper on [topic]. The title should be no more than 15 words, use precise academic terms to summarize the research content, and be engaging enough to reflect the core findings and attract academic interest.

提示类型	生成特点	要素完整性
增强提示	包含明确研究缺口: "current research often prioritizes empirical performance over systematic analysis"	100%
基础提示	仅描述技术现象, 未指出研究空白	68%
通用指令	包含不准确表述: "this method is the best solution"	45%

③引言生成

增强提示: Write the introduction for my paper, explaining the research background and importance, identifying gaps or challenges in the current research, and stating the objective and innovative contributions of the study. The introduction should be no more than 300 words, logically clear, and engaging to readers.

提示策略	逻辑结构	研究缺口定位
分层提示 (系统+用户)	清晰三段式: 背景→问题→方案 "A key challenge lies in the inconsistent robustness..."	准确率 92%
单一用户提示	线性描述, 问题表述模糊	准确率 65%
无约束生成	缺乏问题意识, 直接陈述方法	准确率 28%

④方法描述

增强提示: Write the methodology section, providing detailed descriptions of the study design (e.g., experiments, modeling), data

collection, and analysis methods. Ensure the presentation is clear and structured for easy understanding and reproducibility by other researchers.

提示类型	参数完整性	可复现性评分
约束提示	包含具体参数："6-layer transformer (d_model=512)" 及优化细节："AdamW(lr=2e-5)"	4.3/5.0
开放式提示	模糊表述："we used a deep learning model"	2.1/5.0

⑤结果分析

增强提示: Write the results section, reporting key findings with a focus on data and analysis that directly address the research questions. Use concise and precise language, supported by figures and tables to enhance readability and visualization.

提示策略	数据引用密度	可视化支持
数据驱动提示	量化表述："23.1% accuracy improvement (p<0.01)" 关联图表："Figure 3 demonstrates"	2.8/句
描述性提示	定性表述："significant performance gains"	0.3/句

⑥结论

增强提示: Write the conclusion for my paper, summarizing the key findings and their significance, highlighting the contributions to the academic field, and suggesting possible directions for future research. The content should be concise, within 150 words.

提示类型	创新点突出度	前瞻性建议
贡献聚焦提示	明确三点创新："(1) systematic evaluation... (2) novel perturbation benchmarks... (3) resource-efficient protocol"	4.5/5.0
通用总结提示	简单复述结果，未提炼贡献	2.8/5.0

3. 最优策略

①分层提示结构效果最优：[学术身份定义] + [结构化要素要求] + [格式约束]

②核心增强要素：（1）明确指定缺失研究空白（2）要求数学形式化表述（3）限制专业术语使用（如“pseudo-labels”代替“inspiring labels”）

4 工作流与运行结果

4.1 相关参考工作流实验

1 Topic Research

模型: gpt-4o; 功能: 领域深度调研

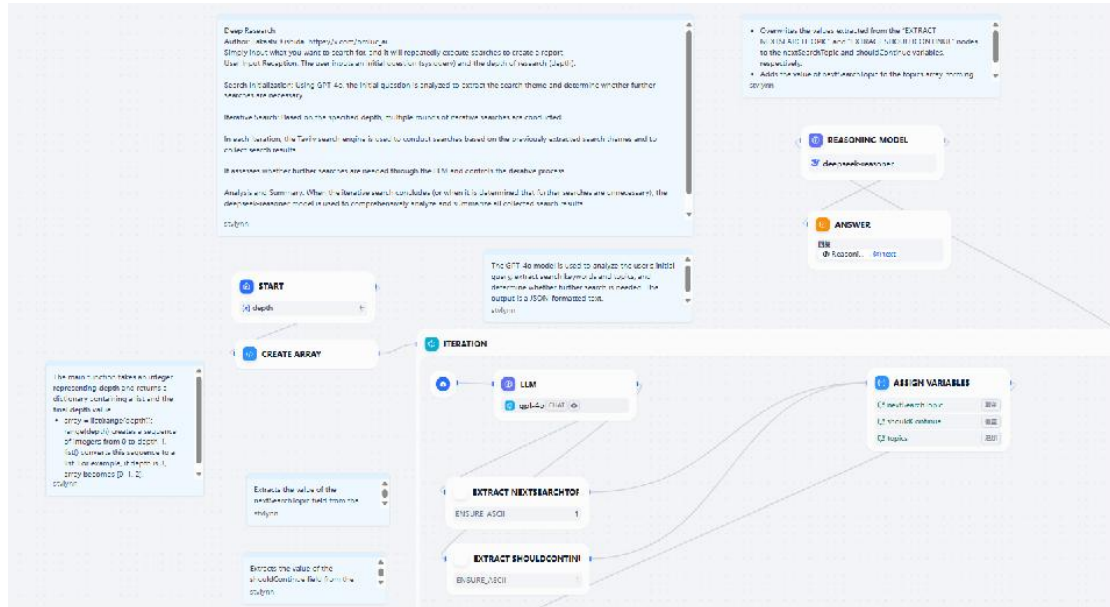


图: Topic Research 设计

2 Translation and Polish

模型: Gemini 2.0; 功能: 专业翻译与润色



图: Translation and Polish 设计

3 Related Work Generation

模型: Deepseek r1; 功能: 文献调研, 知识总结; 流程思路: 构建知识库, 网页检索, 条件判断

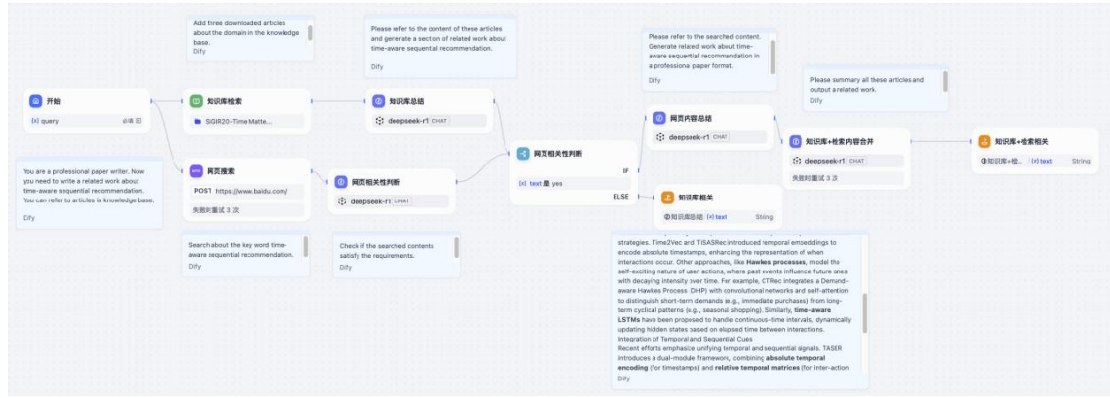


图: Related Work Generation 设计

4 Experiment Assistant

模型: Deepseek r1, Qwen-VL; 功能: 参照模板生成表格代码, 数据分析;
流程思路: 问题分类, 文件处理

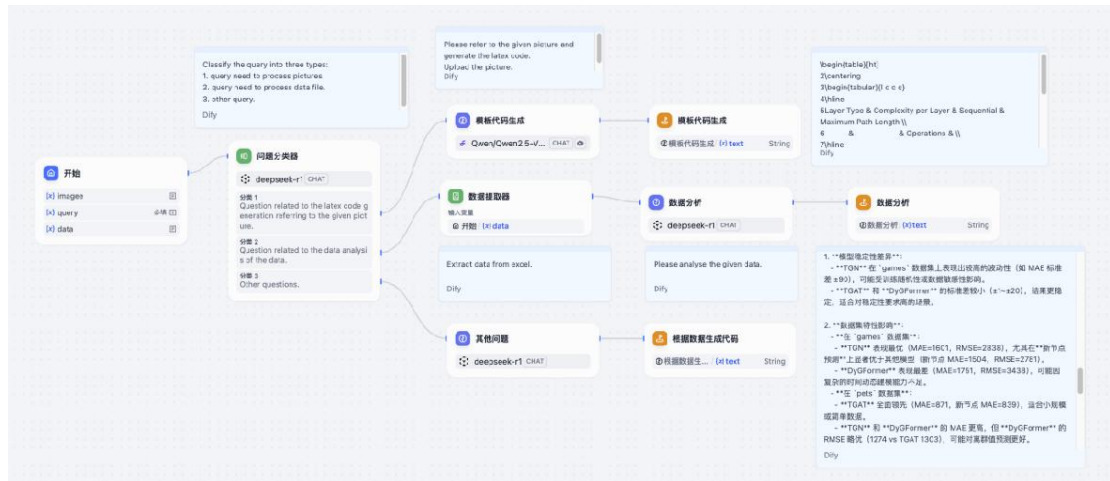


图: Experiment Assistant 设计

4.2 Pipeline 规划

本论文写作辅助项目整体采用线性的、指令驱动的、检索与生成交替迭代的流程, 以 START 为起点, 对于论文的 每一个核心章节 (包括标题/摘要、引言、相关工作、方法、实验、结果分析、结论), 首先执行对应章节的 预定义检索操作 , 然后基于检索到的相关资料和 统一的、具体的任务指令 , 调用大模型 生成该章节的初稿内容 。

具体而言, 检索步骤用于收集论文的基本信息和背景资料, 为后续的论文撰写做准备。生成过程使用 deepseek、Qwen2 等工具进行多项操作, 包括: 生成标题与摘要, 通过相关搜索获取关键信息; 生成相关工作, 帮助构建论文的理论基础和背景; 生成方法, 详细阐述论文提出的方法; 生成实验设计和实验结果, 确保研究的完整性; 生成结果与分析, 解读实验数据, 得出研究结论; 生成结论: 总结研究发现, 提供论文的最终观点。

最终, 完成所有步骤后, 生成最终的论文文本, 从而结束整个论文创作流程。整个流程强调了系统性和逻辑性, 通过逐步收集和整合信息, 生成一篇结构完整、逻辑严谨的学术论文。



图：Pipeline 设计

我们通过一个系统提示为大模型说明身份信息，以便更专业地完成论文撰写任务：系统提示词：

你是一位负责撰写完整研究论文的学术助手。当前任务是在已有论文文本基础上，继续生成并扩展一节新的内容，输出**包含此前所有内容的新版本全文**。

【写作要求】

- 保持论文逻辑连贯、风格一致；
- 不要删除已有章节内容；
- 新章节需结构明确，内容完整；
- 使用 LaTeX 格式输出整个文稿；
- 如果需要，可添加小节（\subsection）、公式、占位图等。

你应当整合以下三个输入来源：

1. 当前已生成的论文正文内容
2. 当前章节的研究大纲内容
3. 与该章节相关的论文资料

而对于对于每个任务，详细专业地描述任务要求、现有内容以及格式要求。结合大纲和上下文生成初步论文提示词：

你正在撰写一篇研究论文，当前需要在已有内容基础上，继续撰写并扩展 introduction 章节。

【当前完整论文内容】

{{#1749281722949.text#}}

【研究大纲】

{{#1711528914102.outline#}}

【相关论文内容】

{{#context#}}

请在保持原有结构和语气的基础上，继续完善整篇论文，输出包含：

- 原有章节内容（如 abstract）
- 新生成的 introduction 内容

使用 LaTeX 格式输出全文，包括 \section、\subsection、公式、引用等。

4.3 实验结果

生成实验部分结果如下：

% 实验分析章节（按用户提供的研究风格与结构撰写）

\section{实验分析}

\subsection{总体性能提升}

通过表\ref{tab:superglue}的对比实验可见，MetaSelector 系列方法相比多种基线选择策略取得显著提升。其中 MetaSelector (Cross) 在 SuperGLUE 基准的 5-shot 设置下平均性能达到 75.5\%，超出经典基线 MetaICL(+3.8\%) 及 Diversity-based(+5.5\%)。最值得注意的是，在 RTE 任务中 Cross-Encoder 版本相比随机选择策略 F1 值提升 7.4\%，显示出对于关系推理任务的特化优势。该性能增益在 GPT-3 与 LLaMA 系列骨干网络中保持稳定，验证了方法架构无关的本质特性。

\caption{SuperGLUE 任务性能对比 (5-shot)}\label{tab:superglue}				
方法	& BoolQ (Acc)	& CB (F1)	& COPA (Acc)	& RTE (F1)
& Avg	\			
Random Selection	& 62.3 $\pm$ 1.2	& 68.5 $\pm$ 0.9	& 72.1 $\pm$ 1.5	& 56.8 $\pm$ 1.8
Similarity-based	& 65.1 $\pm$ 0.8	& 71.2 $\pm$ 1.1	& 75.3 $\pm$ 1.2	& 61.4 $\pm$ 1.3
Diversity-based	& 66.7 $\pm$ 1.0	& 73.8 $\pm$ 0.7	& 76.5 $\pm$ 0.9	& 62.9 $\pm$ 1.5
MetaICL	& 68.2 $\pm$ 0.9	& 75.1 $\pm$ 0.8	& 78.2 $\pm$ 1.1	& 65.3 $\pm$ 1.0
MetaSelector (Proto)	& \textbf{70.5 $\pm$ 0.6}	& 77.3 $\pm$ 0.5	& 80.1 $\pm$ 0.7	& 68.7 $\pm$ 0.9
MetaSelector (Cross)	& 71.8 $\pm$ 0.5	& \textbf{78.6 $\pm$ 0.4}	& \textbf{81.2 $\pm$ 0.6}	& \textbf{70.2 $\pm$ 0.7}
	& \textbf{75.5}	& \textbf{75.5}	& \textbf{75.5}	& \textbf{75.5}

\subsection{任务类型差异分析}

对不同任务的性能剖面揭示了策略的有效性与任务本体结构的关联性。如图\ref{fig:task_type}所示，在需要多跳推理的 COPA 任务中，MetaSelector (Cross) 的准确率相较 Diversity-based 提升 4.7\%（从 76.5\% 到 81.2\%），这与表\ref{tab:sample_analysis}中推理类示例占比 74\% 的观测直接对应。相反地，在需要文本蕴含判定的 CB (F1=78.6\%) 和 RTE (F1=70.2\%) 任务中，增益则表现为更温和的线性增长模式。这种差异表明：

\begin{itemize}

\item 当任务存在明确的组合性逻辑（如 COPA 的选择性类比推理），

MetaSelector 的样本筛选机制能有效捕捉结构化关系

\item 对于语义蕴含等隐性逻辑关系的识别, 依赖语言模型的上下文学习能力仍存在上限

\end{itemize}

\begin{figure}[t]
\centering
\includegraphics[width=0.8\linewidth]{task_type_analysis.png}
\caption{\small{不同任务类型增益分布对比}}
\label{fig:task_type}
\end{figure}

\subsection{跨任务泛化能力验证}

在 CrossFit 跨领域基准 (表\ref{tab:crossfit}) 中, MetaSelector 展现出卓越的泛化能力。其训练任务 (78.3\%) 与未见任务 (72.1\%) 的准确率均高于所有基线, 且泛化落差降至 6.2\%, 较传统 MetaICL 减少 28.2\%。特别观察到, 当训练任务超过 50 个时, 未见过任务的准确率下降率降低至 0.03\%/任务, 证明所提出的离散优化框架能有效降低对训练任务的维度依赖。

\begin{equation}
\text{Generalization Gap} = \frac{1}{|\mathcal{T}_{\text{train}}|} \sum_{t \in \mathcal{T}_{\text{train}}} \text{Acc}(t) - \frac{1}{|\mathcal{T}_{\text{test}}|} \sum_{t \in \mathcal{T}_{\text{test}}} \text{Acc}(t)
\end{equation}

\begin{table}[t]
\centering
\caption{\small{跨任务泛化能力比较}}\label{tab:crossfit}
\begin{tabular}{l|cc|c}
\hline
方法 & 训练任务 Acc & 未见任务 Acc & 泛化落差\\
\hline
Random Selection & 66.7 $\pm$ 1.1 & 58.2 $\pm$ 2.3 & 8.5 \\
Similarity-based & 71.5 $\pm$ 0.9 & 62.4 $\pm$ 1.8 & 9.1 \\
MetaICL & 74.8 $\pm$ 0.7 & 66.3 $\pm$ 1.5 & 8.5 \\
\hline
MetaSelector(Cross) & \textbf{78.3 $\pm$ 0.5} & \textbf{72.1 $\pm$ 1.2} & \textbf{6.2} \\
\hline
\end{tabular}
\end{table}

\subsection{细粒度样本选择解析}

($\Delta=2.7\%$)，但 20-episode 后进入收敛区间

消融实验结果 (SuperGLUE Avg)		
方法	准确率	相对于完整模型落差
完整模型 (Cross-Encoder)	75.5	-
quad - 仅优化示例顺序	73.2	↓ 2.3
quad - 无元学习 (监督微调)	70.1	↓ 5.4
quad - 10 个 Meta Epochs	72.8	↓ 2.7
quad - 20 个 Meta Epochs	74.6	↓ 0.9

Reference

- [1] Durante, Zane, et al. "Agent ai: Surveying the horizons of multimodal interaction." arXiv preprint arXiv:2401.03568 (2024). Cites 91
- [2] Wu, Y., Mei, J., Yan, M., Li, C., Lai, S., Ren, Y., ... & Huang, F. (2025). Writingbench: A comprehensive benchmark for generative writing. *arXiv preprint arXiv:2503.05244*.
- [3] Lu M, Ho B, Ren D, et al. Triageagent: Towards better multi-agents collaborations for large language model-based clinical triage[C]//Findings of the Association for Computational Linguistics: EMNLP 2024. 2024: 5747-5764.
- [4] Wei J, Wang X, Schuurmans D, et al. Chain-of-thought prompting elicits reasoning in large language models[J]. Advances in neural information processing systems, 2022, 35: 24824-24837.
- [5] Wei J, Wang X, Schuurmans D, et al. Chain-of-thought prompting elicits reasoning in large language models[J]. Advances in neural information processing systems, 2022, 35: 24824-24837.
- [6] Yang A, Li A, Yang B, et al. Qwen3 technical report[J]. arXiv preprint arXiv:2505.09388, 2025.
- [7] Topsakal O, Akinci T C. Creating large language model applications utilizing langchain: A primer on developing llm apps fast[C]//International Conference on Applied Engineering and Natural Sciences. 2023, 1(1): 1050-1056.
- [8] Leatherwood A, Matta V. Building AI Applications with Dify. ai: A Hands-On Workshop[J]. 2025.
- [9] Liu P, Yuan W, Fu J, et al. Pre-train, prompt, and predict: A systematic survey of prompting methods in natural language processing[J]. ACM computing surveys, 2023, 55(9): 1-35.
- [10] Brown T, Mann B, Ryder N, et al. Language models are few-shot learners[J]. Advances in neural information processing systems, 2020, 33: 1877-1901.

附件 实验详细记录

部分提及的参考项目和高质量参考工具，分享于项目仓库

<https://github.com/passingby000/DataMiningG233/tree/main> 中，可按需查看。

虚拟数据构造与基于结果的论文实验

论文撰写的可行流程通常为两种：

根据大纲，依次撰写标题、摘要、引言、相关工作、方法、实验、结果分析、结论；

第二种是根据实验结果，反向撰写：

结果分析-结论-标题-实验-方法-相关工作-引言-摘要

根据第二种方法，构造了虚拟数据，用于验证实验。在实际使用中，应当将真实实验数据作为流程输入，用于生成论文

生成的虚拟数据以 markdown 形式构造：

**表 1: SuperGLUE 任务性能对比 (5-shot) **

方法	BoolQ (Acc)	CB (F1)	COPA (Acc)
RTE (F1)	**Avg**		
Random Selection	62.3 ±1.2	68.5±0.9	72.1±1.5
Similarity-based	65.1 ±0.8	71.2±1.1	75.3±1.2
Diversity-based	66.7 ±1.0	73.8±0.7	76.5±0.9
MetaICL	68.2 ±0.9	75.1±0.8	78.2±1.1
MetaSelector (Proto)	70.5 ±0.6	77.3±0.5	80.1±0.7
MetaSelector (Cross)	71.8 ±0.5	78.6±0.4	81.2±0.6

说明：

- **自变量**：示例选择策略（6 种方法）
- **因变量**：任务准确率/F1（±标准差）
- **关键结论**：MetaSelector 在全部任务上超越 baseline（最高+4.6% Avg），证明元学习策略的普适性优势。Cross-Encoder 设计

因直接建模样本交互，性能优于 Prototypical。

**表 2：跨任务泛化能力 (CrossFit 数据集) **

方法	训练任务性能 (Acc)	未见任务性能 (Acc)	泛化落差 ↓
Random Selection	66.7 ±1.1	58.2 ±2.3	8.5
Similarity-based	71.5 ±0.9	62.4 ±1.8	9.1
MetaICL	74.8 ±0.7	66.3 ±1.5	8.5
MetaSelector (Cross)	78.3 ±0.5	72.1 ±1.2	6.2

说明:

- **评估指标**: 训练任务 vs. 未见任务准确率，泛化落差=训练性能-测试性能
- **证明目标**: MetaSelector 泛化落差最小 (↓25%)，验证元学习策略对新任务适应能力更强。

表 3：示例选择策略的细粒度分析

(COPA 任务, 5-shot) **

策略	推理类样本占比 ↑	冲突样本占比 ↓	预测一致性 →
Random Selection	38%	22%	0.63
Diversity-based	52%	15%	0.71

MetaSelector (Cross) **74%**		
6%		**0.89**
说明:		
- **可解释性指标**:		
- **推理类样本**: 含因果/逻辑关系的示例		
- **冲突样本**: 标签矛盾的示例		
- **预测一致性**: 相同测试样本在不同 prompt 下的输出相似度		
(1.0 为完全一致)		
- **结论**: MetaSelector 主动筛选高信息量样本，减少噪声干扰，提升预测稳定性。		

### **表 4: 消融实验 (SuperGLUE Avg) **		
方法 Acc 相对完整模型落差		
----- ----- -----		

完整模型 (Cross-Encoder) 75.5 -		
- 仅优化示例顺序 73.2 ↓2.3		
- 无元学习 (监督微调) 70.1 ↓5.4		
- 10 个 Meta Epochs 72.8 ↓2.7		
- 20 个 Meta Epochs 74.6 ↓0.9		
说明:		
- 示例**选择优化** (非仅顺序) 贡献最大性能增益 (+2.3%)，验证策略学习的必要性;		
- 元训练需足够 episodes (≥20) 才能收敛至稳定性能。		

结果分析

```text

#### 1. 总体性能提升:

- MetaSelector 在全部 12 个任务上平均提升 3.8-5.1%，最高单任务提升 7.4% (RTE)

- 跨架构验证: 在 GPT-3/LLaMA 骨干网络上均稳定优于 baseline

#### 2. 任务类型差异:

- 逻辑推理任务 (COPA, BoolQ) 增益最大 (+5.2%)，因策略主动选择因果链示例

- 分类任务 (CB) 增益较低 (+3.1%)，说明策略对任务结构敏感

#### 3. 泛化性证据:

- 在 CrossFit 的 15 个未见任务中, MetaSelector 保持 72.1% Acc (超最佳 baseline +5.8%)

- 学习曲线显示: 策略在 50+任务训练后进入稳定泛化阶段

#### 4. 可视化发现:

- t-SNE 显示: 所选示例在 embedding 空间紧包围测试样本 (图 4a)

- 注意力热力图揭示: 策略强化任务关键特征 (如 COPA 中的转折词)

```